TP 4 - Fédération de données multi-SGBD avec PySpark

Big Data Engineering - UCAD / FST / DMI - Prof. S. Ndiaye

Contributeurs	Dépôt GitHub
Deschant Kounou & Ulrich Kpassi-Gobi	https://github.com/deschantkn/tp4-federation-multi-sgbd

1. Contexte et objectif

Une plateforme e-commerce sénégalaise répartit ses données entre quatre équipes, chacune avec son propre SGBD, sans aucune clé étrangère entre les systèmes. La direction demande pourtant un chiffre d'affaires consolidé par ville, par catégorie de produit et par moyen de paiement. Aucun SGBD ne sait interroger les trois autres : **Spark**, avec quatre pilotes JDBC dans une seule JVM, joue le rôle de moteur de fédération.

Équipe	Table	SGBD	Base / schéma	Lignes
CRM	clients	MySQL 8.4	ecommerce_crm	12
Catalogue	produits	PostgreSQL 16	ecommerce_catalogue	10
Ventes	commandes	Oracle Free 23ai	SPARK_USER (FREEPDB1)	30
Finance	paiements	SQL Server 2022	ecommerce_paiements	27

2. Environnement mis en place

- Les quatre SGBD tournent en **conteneurs Docker** (`docker-compose.yml`) ; le script `scripts/setup.sh` rejoue la Partie A (exécution des 4 scripts `init_tp4_*.sql` avec le compte administrateur) et contrôle les décomptes 12 / 10 / 30 / 27.
- PySpark 3.5.1 sur Java 17 ; une seule `SparkSession` reçoit les 4 pilotes JDBC via `spark.jars`.
- Adaptations à un Mac Apple Silicon : Oracle XE 21c n'existant pas en ARM, nous utilisons **Oracle Database Free 23ai** (service FREEPDB1) ; PostgreSQL est exposé sur le port **5433**. Les scripts SQL et les résultats sont identiques au sujet.

3. Démarche

- **Lecture** des 4 tables par une fonction unique `lire_jdbc(url, table, pilote)` : seuls l'URL, le nom de table et la classe du pilote changent.
- **Normalisation du dialecte Oracle** : colonnes renvoyées en MAJUSCULES (passées en minuscules) et types NUMBER ramenés en decimal (convertis en int / long). Sur notre instance, NUMBER(12) donne decimal(12,0) ; decimal(38,10) n'apparaît que pour un NUMBER sans précision.
- **Vue fédérée** : chaque DataFrame est exposé en vue temporaire, puis joint en SQL standard, de 2 à 4 SGBD.

- **Audit d'intégrité** par anti-jointures (`LEFT ANTI JOIN`), analyses consolidées, puis écriture du résultat dans l'entrepôt PostgreSQL `analytics.ventes_federees`.

```
SELECT co.commande_id, cl.nom, cl.ville, pr.nom AS produit,
       pr.categorie, pa.moyen_paiement, co.montant_fcfa
FROM commandes co
JOIN clients   cl ON co.client_id   = cl.client_id    -- Oracle x MySQL
JOIN produits  pr ON co.produit_id  = pr.produit_id  -- x PostgreSQL
JOIN paiements pa ON co.commande_id = pa.commande_id -- x SQL Server
WHERE co.statut = 'livree' AND pa.statut_paiement = 'reussi'
```

4. Résultats : de 30 commandes à 22 ventes fédérées

Étape	Lignes	Explication
Commandes (Oracle)	30	point de départ
+ clients (MySQL)	29	CMD21 : client C999 inconnu du CRM
+ produits (PostgreSQL)	28	CMD22 : produit P999 inconnu du catalogue
+ paiements réussis, commandes livrées	22	retrait des 3 annulées (CMD07, CMD15, CMD30) et des 3 en cours (CMD12, CMD26, CMD28)

La jointure interne élimine silencieusement les lignes sans correspondance : sans audit, ces pertes passeraient inaperçues.

5. Audit d'intégrité inter-SGBD

Anomalie	Source	Problème	Impact métier
CMD21	Oracle - commandes	client C999 absent de MySQL	15 000 FCFA encaissés (PAY18) mais exclus du CA par ville ; client impossible à contacter ou facturer.
CMD22	Oracle - commandes	produit P999 absent de PostgreSQL	50 000 FCFA encaissés (PAY19) mais exclus du CA par catégorie ; stock et marge non calculables.
PAY27	SQL Server - paiements	commande CMD99 absente d'Oracle	99 000 FCFA encaissés sans vente : écart comptable, remboursement ou fraude potentielle.

Contrôle complémentaire : les commandes *livrées sans paiement réussi* sont au nombre de **0**. Ce résultat vide prouve la cohérence entre livraisons et encaissements. Le détail figure dans `docs/AUDIT_TP4.md`.

6. Analyses consolidées pour la direction

CA fédéré total : **1 452 000 FCFA** (22 ventes).

Ville	CA (FCFA)
Dakar	723 000
Thies	362 000
Ziguinchor	103 000
Rufisque	85 000
Autres (5 villes)	179 000

Catégorie	CA (FCFA)
Informatique	740 000
Telephonie	400 000
Mode	174 000
Beaute	84 000
Electromenager	54 000

Paiement	CA (FCFA)
Wave	537 000
Carte bancaire	395 000
Orange Money	371 000
Espèces	76 000
Free Money	73 000

Le mobile money (Wave + Orange Money, 908 000 FCFA) représente environ **63 %** du CA, ce qui est typique du e-commerce sénégalais. La table consolidée est écrite dans `analytics.ventes_federees` ; sa relecture renvoie bien 22 lignes.

7. Sous le capot : le predicate pushdown

Le plan physique d'un filtre sur la table Oracle montre `PushedFilters: [*IsNotNull(STATUT), *EqualTo(STATUT,livree)]` et une lecture limitée à 2 colonnes. C'est donc Oracle qui filtre, et seules les lignes utiles traversent le réseau. Sur une table de centaines de millions de lignes, sans pushdown, Spark rapatrierait la table entière avant de filtrer.

8. Discussion et conclusion

- **Limites de la fédération à la volée** : chaque exécution sollicite les 4 bases de production (charge, dépendance à la disponibilité de chacune, lectures non simultanées, pas d'historique). La réponse du cours (séances 6-7) est un pipeline ELT orchestré par **Airflow** vers un lakehouse **Delta Lake** (couches bronze / silver / gold, transactions ACID, time travel).
- **Gouvernance** : sans clé étrangère inter-SGBD, l'intégrité relève de l'organisation. Chaque domaine a besoin d'un responsable des données : le paiement orphelin PAY27 revient à la Finance, en lien avec les Ventes et le contrôle interne. Les anti-jointures d'audit doivent être automatisées à chaque chargement.
- **Bilan** : 4 SGBD en entrée, 1 table consolidée en sortie. Tous les relevés attendus sont obtenus : 22 lignes fédérées, 1 452 000 FCFA de CA et 3 anomalies documentées.